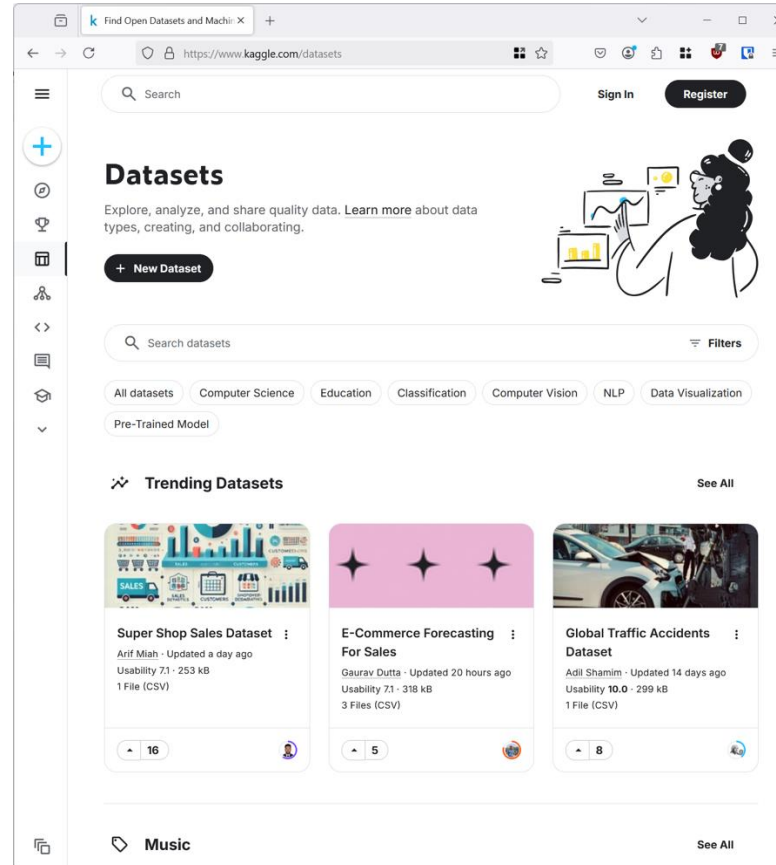


Örüntü Tanıma

Uygulama -3-

Proje Ödevi İçin Fikir Bulma

- <https://Kaggle.com/datasets> adresindeki veri kümelerini kullanabilirsiniz.



Find Open Datasets and Machine Learning Projects

Brain-tumor

https://www.kaggle.com/datasets/ultralitics/brain-tumor

Search

Sign in

Register

Create

Home

Competitions

Datasets

Models

Code

Discussions

Learn

More

ULTRALYTICS AND 2 COLLABORATORS · UPDATED 2 MONTHS AGO

25

New Notebook

Download

Brain-tumor

Train AI to detect brain tumors with MRI/CT data for early diagnosis and better

Data Card

Code (4)

Discussion (0)

Suggestions (0)

About Dataset

A brain tumor detection dataset consists of medical images from MRI or CT scans, containing information about brain tumor presence, location, and characteristics. This dataset is essential for training [computer vision](#) algorithms to automate brain tumor identification, aiding in early diagnosis and treatment planning.

Dataset Structure

The brain tumor dataset is divided into two subsets:

• **Training set:** Consisting of 893 images, each accompanied by corresponding annotations.

• **Testing set:** Comprising 223 images, with annotations paired for each one.

Applications

The application of brain tumor detection using computer vision enables early diagnosis, treatment planning, and monitoring of tumor progression. By analyzing medical imaging data like MRI or CT scans, computer vision systems assist in accurately identifying brain tumors, aiding in timely medical intervention and personalized treatment strategies.

Usage

Train

Dataset is in TIF format and the brain tumor dataset for 100 months with an average size of 8.87 million raw recorded data volume. For a

View more

brain-tumor.yaml (827 B)

Download

Copy

About this file

A YAML (Yet Another Markup Language) file is used to define the dataset configuration. It contains information about the dataset's paths, classes, and other relevant information. In the case of the brain tumor dataset, the `brain-tumor.yaml` file is maintained at <https://github.com/ultralitics/ultralitics/blob/main/ultralitics/cfg/datasets/brain-tumor.yaml>.

Usability

10.00

License

GNU Affero General Public License

Expected update frequency

Monthly

Tags

Computer Science

Biology

Cancer

Programming

Computer Vision

Deep Learning

Object Detection

Data Explorer

Version 2 (4.54 MB)

brain-tumor

brain-tumor.yaml

View Active Events

Bayes Teoremi

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

Bayes Hastalık Örneği

- Toplumda az sıklıkta görülen bir hastalık düşünelim.
Toplumda 100 kişide 1 kişi bu hastalığa sahip.
- Hastalık için bir test var bu test hastaları %90 doğru olasılıkla tahmin ediyor (duyarlılık). Test, hasta olmayanları da %95 oranda doğru tespit ediyor (spesifite)
- Testiniz pozitif çıktığında gerçekten hasta olma olasılığınız nedir?

Bayes Teoremini Uygulayalım

$$P(H|P) = \frac{P(P|H)P(H)}{P(P)}$$

P(H): Toplumda hastalığın görülme olasılığı: %1 = 0.01

P(P|H): Testin hastalığı doğru tespit oranı: %90 = 0.9

$$P(P) = P(P|H)P(H) + P(P|\neg H)P(\neg H)$$

P(P): Testin pozitif çıkma olasılığı:

→ Hastasınız ve pozitif çıktı: 0.01×0.9

→ Hasta değilsiniz ve pozitif çıktı: 0.99×0.05

$$P(P) = 0.009 + 0.0495 = 0.0585$$

Bayes'i uygulayalım:

$$P(H|P) = (0.9 \times 0.01) / 0.0585 \\ = 0.1538 \sim 0.154$$

Yani hasta olma olasılığınız: %15.4

Neden Böyle Oldu?

- Toplumda hastalık çok az görülüyor.
- Örneğin 10,000 kişiden sadece 100 kişi hasta. Geri kalan 9,900 kişi sağlıklı
- Test bu 9,900 kişide $9,900 \times 0,05 = 495$ kişide hatalı sonuç veriyor.
- Gerçek hasta olan 100 kişiden 90'u pozitif çıkıyor.
- Testi pozitif çıkan kişi sayısı = $90 + 495 = 585$ kişi
- Gerçekten hasta olan kişi sayısı = 90
- Bu yüzden pozitif çıksak da hasta olma olasılığımız = $90/585 \approx 0.15$

Prior ve Posterior Olasılıklar

- Test yapmadan önce bir kişinin hasta olma olasılığının %1 olduğunu biliyorduk. Bu bizim öncül (prior) olasılığımızdı.
- Daha sonra yaptığımız testin pozitif çıkması, bu kişinin hasta olma olasılığını arttırdı ve %15'e çıkardı. Bu bizim sonsal (posterior) olasılığımız oldu.

Bayes Python Kodu

```
def bayes_theorem(prior, likelihood, marginal_likelihood):  
    posterior = (likelihood * prior) / marginal_likelihood  
    return posterior  
  
prior = 0.01 # Bir hastalığa sahip olma olasılığı  
likelihood = 0.9 # Testin hasta olan birini doğru tespit etme olasılığı  
false_positive_rate = 0.05 # Testin yanlış pozitif verme olasılığı  
marginal_likelihood = (likelihood * prior) + (false_positive_rate * (1 -  
prior))  
  
posterior = bayes_theorem(prior, likelihood, marginal_likelihood)  
print(f"Test pozitif çıktığında gerçekten hasta olma olasılığı:  
{posterior:.4f}")
```

MLE ve MAP

MLE (Maximum Likelihood Estimation – Maksimum Olabilirlik Tahmini)

→ Bir gözlem kümesi için olasılığı en yüksek yapan parametreleri bulur.

$$L(\theta) = P(X|\theta) = \prod_{i=1}^n P(x_i|\theta)$$

L, bağımsız gözlemler için bir olabilirlik fonksiyonu (likelihood function) olsun. θ ise bu fonksiyonun bir parametresi.

$$\hat{\theta} = \arg \max_{\theta} L(\theta)$$

MLE

- Normalde bir zarın 6 yüzü vardır ve atıldığında her yüzünün gelme olasılığı $1/6$ yani %16.7'dir. Bir zarın hileli olduğundan şüpheleniyoruz.
- 10 defa zarı attık ve 6 sayısı 4 kere geldi.
- MLE'ye göre $4/10 = \%40$ olasılıkla tekrar attığınızda 6 gelir.

MAP

- MAP (Maximum A Posteriori Estimation), önceden elimizde bir tahmin varsa ona göre davranıyor. Başlangıçta zarın adil olduğunu düşünüyorduk ama 10 atışta 4 defa 6 geldi.
- MAP der ki:
 - Önceden adil olduğuna inanıyordum ama, belki zar gerçekten hilelidir.
 - Ama belki de bu şans eseri olmuştur.

Beta dağılımı ön fikir oluşturma

$$P(\theta) \sim \text{Beta}(\alpha, \beta)$$

$P(\theta) = \text{Beta}(2, 10)$ dağılımı oluşturuyoruz.


Zar adil olsa ve zarı 12 kez atsak

$\alpha = 2 \rightarrow$ Başlangıçta 2 kez 6 geldiğini düşünüyoruz.

$\beta = 10 \rightarrow$ Başlangıçta 10 kez 6 gelmediğini düşünüyoruz.

Zarın yaklaşık adil olduğuna inanıyoruz ama kesin de emin değiliz.

Farklı Beta Dağılımları



$$\hat{\theta}_{MAP} = \frac{k + \alpha - 1}{n + \alpha + \beta - 2}$$

$k \rightarrow$ gözlemde kaç kez 6 geldi. (4 kez)

$n \rightarrow$ gözlemde kaç kere zar attık (10 kez)

$\alpha, \beta \rightarrow$ Önceden düşüncemiz

$$= (4 + 2 - 1) / (10 + 2 + 10 - 2) = 5/20 = 0.25$$

Öncül bilgimiz, MLE'ye göre oranı %40'tan %25'e çekti.

Bu zarın hilesiz olduğunu düşünüyorduk, ama gözlemlerimiz aksi olabileceği yönünde çıktı.

Bu iki fikrimizi birleştirirsek %25 olasılıkla yine 6 gelebilir.

- Bu durumda MAP önceki bilgilerimizden yararlanarak daha etkili tahmin yapmamızı sağlayabilir. Elimizde az veri olduğunda daha kullanışlı olabilir.
- Eğer zar adilse, ileriki gözlemlerimiz ile MAP ve MLE'nin birbirine yaklaştığını görebiliriz.